Análise de Vendas do Supermercado — Explicação do Projeto

Sep 26, 2026 · @macutang

Visão geral

O projeto analisa todas as vendas de um supermercado em 2023 para responder perguntas de negócio: o que vende mais, quando, para quem e se as promoções funcionam.

É um trabalho de Estatística com três partes:

- **Perguntas de negócio (1 a 10):** respondidas com somas, médias, rankings e gráficos.
- **Estatística descritiva:** resumir cada variável (média, mediana, dispersão, valores atípicos, correlações) e explicar o que cada número quer dizer para a loja.
- **Estatística inferencial (11 a 14):** testes A/B e intervalos de confiança, para saber se uma diferença é real ou só acaso.

Tudo é feito em Python. O arquivo main.py responde às perguntas e o arquivo functions.py guarda as funções reutilizáveis que o main.py chama.

Os dados

O arquivo `csv/vendas_supermercado_com_cliente.csv` tem cerca de 20 mil linhas. Cada linha é uma venda de um produto em um dia de 2023, com dados do cliente que comprou.

Coluna	O que significa	Exemplo
Data	Dia da venda	2023-01-01
Produto	Item vendido	Maçãs
Categoria	Grupo do produto	Alimentos Frescos
Preço	Preço unitário (R$)	16,46
Quantidade	Unidades compradas	10
Desconto	Desconto aplicado (0 = sem promoção)	0,0
Total_Venda	Valor pago na venda (R$)	164,60
Idade	Idade do cliente (anos)	49

Coluna	O que significa	Exemplo
Renda	Renda do cliente (R$)	2.715,61

Ao carregar o arquivo, o código cria colunas extras que facilitam as análises:

Coluna criada	Como é calculada
Mes / Nome_Mes	Mês da data (1 a 12 / Jan a Dez)
Dia_Semana	Segunda a Domingo
Faixa_Etaria	Jovem (até 35), Adulto (36 a 59), Idoso (60+)
Tem_Desconto	Verdadeiro quando Desconto > 0

As questões

As perguntas 1 a 10 já têm resposta no main.py. As partes de estatística descritiva e as perguntas 11 a 14 têm as funções prontas em functions.py, mas ainda não são chamadas no main.py.

Perguntas de negócio (1 a 10)

#	Pergunta, em palavras simples	Como o código responde	Resultado principal
1	Quais categorias vendem mais e em que mês cada uma tem seu pico?	Soma o Total_Venda por categoria e por mês; pega o mês de maior valor	Alimentos Frescos lidera com R$ 1,37 mi (27,7%), 2,6x a Mercearia; pico em março
2	As promoções aumentam as vendas? Quais produtos crescem mais com desconto?	Compara a média com e sem desconto; calcula a variação da quantidade por produto	Venda média cai de R$ 256 para R$ 206 com desconto; quantidade quase igual (10,0). Frango (+13,9%) e Farinha (+12,6%) crescem mais
3	Quanto cada categoria vende, em média, por dia?	Soma as vendas de cada dia por categoria e tira a média dos dias	Alimentos Frescos R$ 3.741/dia; Utilidades Domésticas R$ 985/dia

#	Pergunta, em palavras simples	Como o código responde	Resultado principal
4	Quais produtos têm vendas mais sazonais (variam muito ao longo do ano)?	Coeficiente de variação das vendas mensais de cada produto	Descartáveis (23,1%), Vinhos (23,0%), Sucos (22,9%)
5	Qual faixa etária mais contribui para o faturamento?	Soma das vendas por faixa etária e sua participação	Adultos 42,6%, Jovens 31,1%, Idosos 26,3%
6	Como as vendas se distribuem nos dias da semana?	Média, soma e contagem das vendas diárias por dia da semana	Muito equilibrado: de R$ 13.198 (terça) a R$ 13.655 (quarta) por dia
7	As vendas de novembro (Black Friday) superam os meses anteriores?	Total por mês e comparação de novembro com outubro e com a média de Jan–Out	Novembro vendeu 7,5% menos que outubro; não houve pico
8	Qual o ticket médio de cada faixa etária, e como muda por categoria?	Média do Total_Venda por faixa etária e por categoria × faixa	Quase igual: Adulto R$ 247,79, Idoso R$ 247,33, Jovem R$ 242,19
9	A idade do cliente influencia o valor da compra?	Correlação de Pearson e de Spearman entre Idade e Total_Venda	r = 0,01: nenhuma relação
10	A semana da Black Friday foi melhor que a do Natal?	Vendas diárias de 3 dias antes a 3 dias depois de 24/11 e de 25/12	Natal melhor: R$ 11.871/dia contra R$ 10.931/dia

Estatística descritiva

Para Preço, Quantidade, Desconto, Total_Venda, Idade e Renda, o trabalho pede:

- **Centro e dispersão:** média, mediana, moda, desvio padrão, variância, amplitude e coeficiente de variação.
- **Posição:** quartis e percentis.
- **Valores atípicos (outliers):** boxplot, regra de 1,5 × IQR e z-score, discutindo se devem ser mantidos, tratados ou removidos.
- **Forma:** histograma, assimetria e curtose de Total_Venda e Idade, com comentário sobre normalidade.
- **Tabelas de frequência:** por categoria, faixa etária, dia da semana e mês.

- **Correlação:** matriz de Pearson/Spearman e mapa de calor.

Cada número deve vir com uma frase explicando o que ele significa para a loja.

Estatística inferencial (11 a 14)

Cada teste A/B informa H0, H1, α = 0,05, a estatística do teste, o p-valor e a conclusão para o negócio.

#	Pergunta, em palavras simples	Técnica
11	Vendas com desconto têm valor médio diferente das vendas sem desconto?	Teste A/B (A = sem desconto, B = com desconto)
12	As vendas diárias da semana da Black Friday diferem das da semana do Natal?	Teste t para duas amostras + IC 95% da média diária de cada semana
13	Qual a faixa provável do ticket médio geral e de cada faixa etária?	IC 95%, discutindo por que alguns intervalos são mais largos
14	A média de vendas de novembro difere da de outubro?	Teste A/B (A = outubro, B = novembro)

O código

O código está dividido em dois arquivos: functions.py faz o trabalho pesado e main.py usa essas funções para responder cada pergunta, na ordem.

Arquivo	Papel
main.py	Carrega os dados e responde às perguntas 1 a 10, imprimindo tabelas e salvando gráficos
functions.py	Caixa de ferramentas: carregamento, estatísticas, gráficos e testes (importada como `f`)
estatistica.py	Versão anterior e comentada de functions.py; o main.py não a usa

Como o main.py funciona

1. Importa pandas, numpy, matplotlib e o functions.py.
2. Ajusta o pandas para mostrar números com 2 casas decimais.
3. Chama `f.carregar_dados(...)`, que lê o CSV e cria as colunas extras.

4. Para cada pergunta: agrupa os dados (`groupby` ou `pivot_table`), calcula somas ou médias, imprime o resultado e, em algumas, salva um gráfico na pasta `graficos/`.

Dois recursos do pandas aparecem em quase todas as perguntas:

- **`groupby`**: separa as linhas em grupos (por exemplo, uma pilha por categoria) e resume cada grupo com uma soma ou média.
- **`pivot_table`**: monta uma tabela cruzada, como categorias nas linhas e meses nas colunas.

Funções do functions.py

Preparação dos dados

Função	O que faz
`carregar_dados`	Lê o CSV, converte a data e cria Mes, Nome_Mes, Dia_Semana, Faixa_Etaria e Tem_Desconto
`classificar_faixa_etaria`	Corta as idades em Jovem, Adulto e Idoso com `pd.cut`

Agregações usadas nas perguntas

Função	O que faz
`vendas_por`	Soma (ou média) do Total_Venda por uma coluna, do maior para o menor
`vendas_diarias`	Total vendido em cada dia do ano
`semana_em_torno`	Devolve o início e o fim de uma semana de 7 dias centrada numa data
`filtrar_pedidos`	Pega só as vendas entre duas datas
`coeficiente_variacao_mensal`	Mede o quanto as vendas mensais de cada produto oscilam (desvio ÷ média × 100)

Estatística descritiva

Função	O que faz
`medidas_descritivas` / `tabela_descritiva`	Calcula média, mediana, moda, desvio, variância, quartis, percentis, assimetria e curtose de uma ou várias colunas

Função	O que faz
`interpretar_cv`, `interpretar_assimetria`, `interpretar_curtose`	Transformam o número em frase (ex.: "alta dispersão")
`outliers_iqr`, `outliers_zscore`, `resumo_outliers`	Encontram e contam valores atípicos pelas duas regras
`tabela_frequencia`	Frequência absoluta, relativa e acumulada de uma coluna
`matriz_correlacao`, `interpretar_correlacao`, `correlacoes_relevantes`	Calculam correlações, classificam a força e listam os pares mais fortes

Gráficos (todos salvos em `graficos/`)

Função	Gráfico
`grafico_barras`	Barras (ex.: vendas por categoria)
`grafico_linha`	Linha (ex.: vendas por mês)
`grafico_heatmap`	Mapa de calor (correlações, ticket por categoria × faixa)
`grafico_boxplots`	Boxplot de cada variável numérica
`grafico_histograma`	Histograma com a curva normal para comparação

Estatística inferencial

Função	O que faz
`intervalo_confianca`	IC 95% da média usando a distribuição t
`ic_por_grupo`	O mesmo IC para cada grupo (ex.: cada faixa etária)
`teste_ab`	Teste t de Welch entre A e B, Mann-Whitney como conferência e d de Cohen (tamanho do efeito)
`imprimir_teste_ab`, `imprimir_ic`	Imprimem H0, H1, α, estatística, p-valor e a conclusão em texto

Pontos de atenção no código atual

- `interpretar_assimetria` não trata assimetria negativa (devolve nada) e, para a positiva, devolve uma tupla de dois textos em vez de uma frase só; além disso, na assimetria positiva a média fica *acima* da mediana.
- `interpretar_cv` escreve "disperção"; o correto é "dispersão".
- As funções de estatística descritiva e inferencial ainda não são chamadas no main.py.

Como executar e ler os resultados

Rode `python main.py` dentro da pasta do projeto. As respostas aparecem no terminal e os gráficos são salvos em `graficos/`.

Bibliotecas necessárias: pandas, numpy, matplotlib, seaborn e scipy (`pip install pandas numpy matplotlib seaborn scipy`).

Como ler as saídas:

- **Tabelas de totais e médias:** valores em R$; "Part. (%)" é a fatia de cada grupo no faturamento.
- **Coeficiente de variação:** quanto maior, mais o valor oscila. Abaixo de 15% é estável; acima de 30% é muito variável.
- **Correlação (r):** vai de -1 a 1. Perto de 0 significa que uma coisa não acompanha a outra.
- **p-valor:** abaixo de 0,05, a diferença entre os grupos provavelmente é real; acima, pode ser só acaso.
- **Intervalo de confiança 95%:** faixa onde a média verdadeira provavelmente está. Faixa estreita = estimativa mais precisa.

O que os resultados já mostram para a loja:

- Alimentos Frescos é o carro-chefe e merece prioridade de estoque e exposição.
- Descontos não aumentaram a quantidade vendida e reduziram o valor médio da venda.
- A Black Friday não gerou pico: novembro vendeu menos que outubro, e a semana do Natal foi melhor.
- Idade quase não muda o ticket médio; adultos pesam mais no faturamento porque são mais numerosos, não porque gastam mais por compra.

Glossário

Termo	Explicação simples
Média	Soma dos valores dividida pela quantidade

Termo	Explicação simples
Mediana	Valor do meio quando tudo está em ordem; não é puxada por valores extremos
Moda	Valor que mais se repete
Desvio padrão	Distância típica dos valores até a média
Variância	Desvio padrão ao quadrado
Amplitude	Maior valor menos o menor
Coeficiente de variação (CV)	Desvio padrão em % da média; permite comparar a oscilação de coisas de tamanhos diferentes
Quartis (Q1, Q2, Q3)	Valores que dividem os dados em 4 partes iguais; Q2 é a mediana
Percentil	P90 = valor abaixo do qual estão 90% dos dados
IQR	Q3 − Q1: a faixa onde está a metade central dos dados
Outlier	Valor muito fora do padrão (abaixo de Q1 − 1,5×IQR, acima de Q3 + 1,5×IQR ou com z-score acima de 3)
Z-score	Quantos desvios padrão um valor está longe da média
Assimetria	Se a distribuição tem uma "cauda" mais longa para um lado
Curtose	Se as caudas são mais pesadas (mais extremos) ou mais leves que numa curva normal
Correlação de Pearson	Mede relação em linha reta entre duas variáveis (-1 a 1)
Correlação de Spearman	Igual, mas usando a ordem dos valores; menos sensível a outliers
H0 (hipótese nula)	"Não há diferença" entre os grupos
H1 (hipótese alternativa)	"Há diferença" entre os grupos
α (alfa)	Limite de erro aceito, aqui 0,05 (5%)
p-valor	Chance de ver uma diferença desse tamanho só por acaso, se H0 fosse verdade

Termo	Explicação simples
Teste t de Welch	Compara as médias de dois grupos sem supor que têm a mesma variabilidade
Mann-Whitney	Teste parecido que não exige dados com forma normal; usado como conferência
d de Cohen	Tamanho da diferença em desvios padrão; abaixo de 0,2 é pequena
Intervalo de confiança (IC)	Faixa que provavelmente contém a média verdadeira
DataFrame	Tabela do pandas, com linhas e colunas
`groupby`	Agrupa linhas iguais numa coluna para resumir cada grupo
`pivot_table`	Cria uma tabela cruzada (linhas × colunas)
`pd.cut`	Divide números em faixas (ex.: idades em faixas etárias)